



GOAI TRACK 3

开放探索赛题

定义问题， 而不只优化答案

从 AI for Science 的范式演进，
到一个可提交、可运行、可继续的研究环境

直播说明会 · 30 min

当一个指标成为目标， 它就不再是一个好指标。

Goodhart's law 的经典表述

enhancement, had been built irrevocably into the term improvement.

When a measure becomes a target, it ceases to be a good measure. The more a 2.1 examination performance becomes an expectation, the poorer it becomes as a discriminator of individual performances. Hoskin describes this as 'Goodhart's law', after the latter's observation on instruments for monetary control which lead to other devices for monetary flexibility having to be invented. However, targets that seem measurable become enticing tools for improvement. The linking of improvement to commensurable increase produced practices of wide application. It was that conflation of 'is' and 'ought', alongside the techniques of quantifiable written assessments, which led in Hoskin's view to the modernist invention of accountability. This was articulated in Britain for the first time around 1800 as 'the awful idea of accountability' (Ref. 3. p. 268).

Strathern, European Review 5(3), 1997



3765 个 benchmark 中，大量任务迅速趋于停滞或饱和

Ott et al., Nature Communications 13, 6793 (2022) · arXiv:22.03.04592

01 / FROM PREDICTION TO AGENCY

AI4S 的成功，长期建立在“问题已被定义”之上

过去十年，AI 不断扩大自己能够承担的研究环节；但多数代表性工作仍从专家预先定义的问题、数据与目标出发。

2021

PREDICT

Article

Highly accurate protein structure prediction with AlphaFold

<https://doi.org/10.1038/s41586-021-03819-2>

Received: 11 May 2021

Accepted: 12 July 2021

Published online: 15 July 2021

Open access

 Check for updates

John Jumper^{1,2,3,4}, Richard Evans^{1,2}, Alexander Pritzel^{1,2}, Tim Green^{1,2}, Michael Figurnov^{1,2}, Olaf Ronneberger^{1,2}, Kathryn Tunyasuvunakool^{1,2}, Russ Bates^{1,2}, Augustin Židek^{1,2}, Anna Piatasenko^{1,2}, Alex Bridgland^{1,2}, Clemens Meyer^{1,2}, Simon A. A. Kohl^{1,2}, Andrew J. Ballard^{1,2}, Andrew Cowie^{1,2}, Bernardino Romera-Paredes^{1,2}, Stanislaw Nikolov^{1,2}, Rishub Jain^{1,2}, Jonas Adler^{1,2}, Trevor Back^{1,2}, Stig Petersen^{1,2}, David Raiman^{1,2}, Ellen Clancy^{1,2}, Michal Zelnik^{1,2}, Martin Steinegger^{1,2}, Michalina Pacholika^{1,2}, Tamas Berghammer^{1,2}, Sebastian Bodenstein^{1,2}, David Silver^{1,2}, Oriol Vinyals^{1,2}, Andrew W. Senior^{1,2}, Koray Kavukcuoglu^{1,2}, Pushmeet Kohli^{1,2} & Demis Hassabis^{1,2,3,4}

Proteins are essential to life, and understanding their structure can facilitate a mechanistic understanding of their function. Through an enormous experimental effort¹⁻³, the structures of around 100,000 unique proteins have been determined⁴, but this represents a small fraction of the billions of known protein sequences^{5,6}. Structural coverage is bottlenecked by the months to years of painstaking effort required to determine a single protein structure. Accurate computational approaches are needed

在既定任务上逼近实验精度

DOI: [10.1038/s41586-021-03819-2](https://doi.org/10.1038/s41586-021-03819-2)

2023

GENERATE

MatterGen: a generative model for inorganic materials design

Claudio Zent^{1,2}, Robert Pinski^{1,2}, Daniel Ziegner^{1,2}, Andrew Fowler^{1,2}, Matthew Horton^{1,2}, Xiang Fu^{1,2}, Aleksandra Shvets^{1,2}, Jonathan Crabbe^{1,2}, Lixin Sun^{1,2}, Jake Smith^{1,2}, Bekken Nguyen^{1,2}, Hannes Schulz^{1,2}, Sarah Lewis^{1,2}, Chin-Wei Huang^{1,2}, Ziheng Lu^{1,2}, Yichi Zhou^{1,2}, Han Yang^{1,2}, Hongxin Hao^{1,2}, Jielan Li^{1,2}, Ryota Tomioka^{1,2}, Tian Xie^{1,2}

¹Microsoft Research AIScience.

*Corresponding author(s). E-mail(s): ryoto@microsoft.com; tianxie@microsoft.com;

¹Equal contribution; non-corresponding authors are listed in random order.

从预测走向约束条件下的生成

arXiv:2312.03687

2024

ACT

The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery

Chris Lu^{1,2,3,4}, Cong Lu^{1,4,5}, Robert Tjarko Lange^{1,2}, Jakob Foerster^{1,2}, Jeff Clune^{1,4,5,6} and David Ha^{1,7}

¹Equal Contribution, ²Stanford AI, ³FLAIR, University of Oxford, ⁴University of British Columbia, ⁵Nectar Institute, ⁶Canada CIFAR AI Chair, ⁷Google AI

One of the grand challenges of artificial general intelligence is developing agents capable of conducting scientific research and discovering new knowledge. While frontier models have already been used as aides to human scientists, e.g. for brainstorming ideas, writing code, or prediction tasks, they still conduct only a small part of the scientific process. This paper presents the first comprehensive framework for fully automatic scientific discovery, enabling frontier large language models (LLMs) to perform research independently and communicate their findings. We introduce THE AI SCIENTIST, which generates novel research ideas, writes code, executes experiments, visualizes results, describes its findings by writing a full scientific paper, and then runs a simulated review process for evaluation. In principle, this process can be repeated to iteratively develop ideas in an open-ended fashion and add them to a growing archive of knowledge, acting like the human scientific community. We demonstrate the versatility of this approach by applying it to three distinct subfields of machine learning: diffusion modeling, transformer-based language modeling, and learning dynamics. Each idea is implemented

1 SEP 2024

Agent 开始覆盖完整研究流程

arXiv:2408.06292

能力正在从预测答案扩展到生成候选、运行研究流程。现在，问题与探索空间本身也可以成为 AI 参与设计的对象。



工具变强之后， 瓶颈开始上移

工具侧 模型、Prompt 与调用链已经十分丰富

研究侧 值得被结构化的问题仍然稀缺

比赛聚焦 环境、反馈与发现信号

从“用 AI 解一道题”
走向“用 AI 建立一个能持续出题、试错和修正的研究场”

开放赛道：寻找一个“值得被这样定义”的未解问题

01 赛题类型定位

部分重要的科学问题尚未被结构化为标准的评测任务。开放探索赛题面向这类问题，鼓励参赛者自己提出并定义一个值得探索的科学问题，把它转化为一个 Agent 可以进入、尝试、修正并持续探索的环境。

参赛团队在自己所在的科学或研究领域中，找到一个尚无公认答案的问题，定义相应的探索环境与发现信号，构建可运行的探索系统，并说明探索过程带来的科学或研究价值。与算法赛题不同，本类题目不预设标准答案，负结果被明确允许——关键在于能否清晰解释探索过程说明了什么。

[参赛手册原文](#) · p.28

开放仍然有边界

学科和问题来源可以很宽；
研究交付需要清楚的基本结构。

- 真实存在、尚无公认答案或未被充分结构化
- Agent 可以观察、行动、获得反馈并继续探索
- 正结果、异常、反例与稳定负结果都可成为发现信号

本赛道聚焦尚未结构化的问题；现有 **benchmark** 提分更适合算法赛道。

03 / RESEARCH ENVIRONMENT

研究环境：Agent 可以观察、行动并收到反馈的地方




环境可以是模拟器、文献空间、数据库、市场微观结构或社会系统模型；不必长得像 RL Gym

04 / BROADER SCOPE

Beyond natural science: 社会与金融系统也可以成为研究环境

研究对象可以是自然系统，也可以由个体、制度、信息与激励共同构成。关键仍是把问题写成可干预、可观察、可验证的闭环。



开放赛道关注 共识如何形成 · 合作何时稳定 · 微观行为怎样聚合成系统规律

提交时补上 真实数据 / 人类实验验证、敏感性分析与伦理边界

05 / INNOVATION MATRIX

三条创新路径：可以从成熟数据和模拟器起步

横轴是问题创新度，纵轴是环境 / 探索范式创新度。评分不按象限排序，而看定义是否成立、闭环是否可信。

环境 / 范式创新



研究问题创新

推荐多数团队从 B 类开始

- 成熟数据与模拟器降低工程风险
- 把创新集中在目标、行动和反馈
- 更容易在复赛跑通最小闭环

象限不代表等级。评委会追问：你究竟重新定义了什么？

06 / PRELIMINARY ROUND

初赛：用四页证明“这个问题值得继续探索”

- 失败结果是否能帮助改进下一版问题定义？

06 提交要求（开放探索赛题）

按初赛、复赛、决赛三阶段提交，各阶段均为必交。

阶段	提交材料与内容说明	是否必交
初赛	问题定义文档（≤ 4 页）：说明看见了什么问题、为什么 AI 可以介入、如何定义探索环境、什么算发现信号、最小参照系是什么。	是
复赛	最小可运行探索环境、探索日志、参照系设计：提交可运行环境、至少一次完整运行日志、随机探索或平凡解等参照系，以及 README 与复现说明。	是
决赛	探索报告、答辩材料、最终代码仓库：说明探索过程中的正结果、负结果、异常或问题修正究竟意味着什么；负结果被明确允许。	是

手册原表 · p.35

≤ 4


页问题定义文档

- 01 你看见了什么真实问题？
- 02 为什么它还没有公认答案或尚未被结构化？
- 03 Agent 在哪里行动、看到什么、改变什么？
- 04 什么算发现？最小参照系是什么？

不要求顶会论文、不要求大规模训练、也不要求先得到正结果。

07 / SEMIFINAL

复赛：让最小闭环真实地跑一遍



一次完整而诚实的失败，比十张无法复查的漂亮结果图更有价值。

评委如何判断一个研究定义是否成立

评审维度	建议权重	说明
问题定义与环境设计质量	45%	问题是否真实且切片得当；环境是否抓住问题本质；固定部分、可探索部分和反馈机制是否清楚。
探索过程与科学/研究信号	35%	是否有意义信号：正向发现、异常、反例、被清晰解释的负结果，或问题定义的有效修正。
可检查性与可延续性	20%	是否有最小参照系、运行日志、复现说明和后续研究路径；能否沉淀为社区可接续的问题包或环境包。

手册原表 · p.36

45% 问题定义与环境

问题真实、切片得当、环境抓住本质

35% 探索过程与研究信号

过程是否带来新认识或有效修正

20% 可检查与可延续

别人能否复现、质疑并接着做

环境设计直接体现你如何理解这个问题。

案例一 | Battery-Sim-Agent: 让模拟器进入推理闭环

KDD 2026

DOI:10.1145/3770855.3818856

Battery-Sim-Agent: Leveraging LLM-Agent for Inverse Battery Parameter Estimation

Jiawei Chen^{*}
 Peking University
 Beijing, China
 Shengyu Tao
 Chalmers University of Technology
 Gothenburg, Sweden
 Xiaofan Gui[†]
 Microsoft Research
 Beijing, China
 Shun Zheng
 Microsoft Research
 Beijing, China
 Jiang Bian
 Microsoft Research
 Beijing, China
 Shikai Fang[‡]
 Zhejiang University
 Hangzhou, Zhejiang, China
 Weiqing Liu[†]
 Microsoft Research
 Beijing, China

Abstract


Parameterizing high-fidelity "digital twins" of batteries is a critical but challenging inverse problem that hinders the mass of bat

ACM Reference Format:

Jiawei Chen, Xiaofan Gui, Shikai Fang, Shengyu Tao, Shun Zheng, Weiqing Liu, and Jiang Bian. 2026. Battery-Sim-Agent: Leveraging LLM-Agent for Inverse Battery Parameter Estimation.

研究问题

只观察得到电压、电流和容量曲线，如何反推出不可直接测量的微观电化学参数？



论文构造的环境

- PyBaMM 高保真模拟器负责执行实验
- 曲线、分解残差和求解器事件组成多模态反馈
- Agent 形成物理假设，并以 JSON 更新参数

把 Battery-Sim-Agent 放进开放赛道模板

问题定义

从宏观充放电轨迹推断微观电化学参数，支持高保真数字孪生。难点来自黑箱、非可微、病态性与参数耦合。

研究环境

固定：PyBaMM / DFN、化学体系、协议、参数边界、目标数据。
Agent：读取反馈，修改物理参数 θ 。

探索过程

20 轮随机扰动建立局部敏感性知识；80 轮根据反馈形成假设、更新参数、运行模拟并写入动态记忆。

发现信号

总 MAPE / RMSE、分解后的容量与电压残差、曲线形状、求解失败事件；合成任务中还检查参数恢复是否同步改善。

参照与非平凡 baseline

最低参照：文献默认参数、固定随机搜索。
非平凡参照：Ax Bayesian Optimization；另含 GPT-OSS 消融与 CMA-ES 尝试。

可检查与可延续

开源 PyBaMM 参数集、50 个合成测试、CALCE 真实数据、完整运行预算和消融。后续可扩展新化学体系、协议、噪声与混合优化器。

借鉴重点

把模拟器输出加工成 Agent 能利用的研究反馈，并让每次参数更新带着可解释假设。

参赛时仍需

进一步提出新的研究问题；单纯复现参数估计提分，仍会落回已知任务。

案例二 | CodeScientist: 从文献与代码到可运行实验

Findings of ACL 2025

[arXiv:2503.22708](https://arxiv.org/abs/2503.22708)

CODESCIENTIST: End-to-End Semi-Automated Scientific Discovery with Code-based Experimentation

Peter Jansen^{1,3}, Oyvind Tafjord¹, Marissa Radensky¹, Pao Siangliulue¹,
Tom Hope^{1,4}, Bhavana Dalvi Mishra¹, Bodhisattwa Prasad Majumder¹,
Daniel S. Weld^{1,2}, Peter Clark¹

¹Allen Institute for Artificial Intelligence, ²University of Washington,
³University of Arizona, ⁴Hebrew University of Jerusalem
peterj@allenai.org

它构造了什么?

- 输入: 领域论文 + 可复用 codeblocks
- 生成: 候选想法、实验计划和可运行代码
- 执行: generate-execute-reflect 调试循环
- 输出: 报告、重复实验和跨实验 meta-analysis

19

个候选发现

6

个经人工评估达到最低科学性与增量新颖性





Figure 1: An overview of the core stages of the CODESCIENTIST discovery workflow, including ideation, planning, building and executing code-based experiments, reporting results, and performing meta-analyses across experiments.

Experiment 6: 一项窄而可检查的 60 分实验



0.29

Graph Agent

0.12

ReAct Agent

Task completion: 两组均为 0%

问题定义

结构化知识图谱记忆，能否改善科学探索中的行动与假设生成？

研究环境

DiscoveryWorld Proteomics; 每个 episode 最多 50 步。
Agent 寻找设备、测量蛋白、生成并检验假设。

过程与信号

50 episodes; 过程分数、任务完成率、图复杂度、蛋白测量数量。核心信号是 0.29 vs 0.12。

参照与 baseline

最低参照：无结构化图记忆的基本状态跟踪。
非平凡 baseline：标准 ReAct Agent。

可检查与延续

公开报告、代码、结果和随机种子；后续可增加独立重复、图质量分析和更强任务完成机制。


它的上限在哪里

两组都没有完成最终任务，样本规模仍小。当前结论只支持“改善局部探索过程”，暂不支持“完成科学发现”。

[Report + code · github.com/allenai/codescientist](https://github.com/allenai/codescientist)


[DiscoveryWorld · arXiv:2406.06769](https://arxiv.org/abs/2406.06769)

案例之后，再看一个极简实现：Autoresearch



一次实验固定 5 分钟

读取 val_bpb $\rightarrow$ keep / discard $\rightarrow$ 下一轮



`prepare.py`

FIXED

数据、评测、预算和运行工具

`train.py`

EDITABLE

Agent 每轮允许修改的对象

`program.md`

PROTOCOL

人类定义研究协议与保留规则

可以直接借用

fixed / editable / evaluator / log 的代码边界

需要替换

把 val_bpb 换成你自己的研究反馈与保留逻辑

14 / REUSE REFERENCE


开源环境参考：可以借什么，还要重新定义什么

项目 / 环境	它提供的基础	适合直接复用	参赛作品需要补上的定义
Autoresearch	轻量代码骨架	fixed / editable 边界；预算；单轮评价；keep/discard 日志	新的问题、反馈信号与保留规则；val_bpb 本身不构成开放赛题
DiscoveryWorld	虚拟科学发现环境	120 个任务；观察/行动接口；过程、知识与完成度指标；完整轨迹	新的研究问题或干预范式；仅替换 Prompt 提升通关率仍属于旧任务
PyBaMM	开源电池多物理场模拟器	电化学模型、求解器、公开参数集、实验协议和失败事件	Agent 能改变什么、反馈怎样结构化、什么现象值得探索
dZiner	材料逆向设计闭环	约束、代理模型、候选生成与验证流程	换到新的设计问题、发现信号或物理机制；避免复述既有论文任务

会后阅读链接 [karpathy/autoresearch](#) · [allenai/discoveryworld](#) · [pybamm-team/PyBaMM](#) · [mehradans92/dZiner](#)

15 / NEGATIVE EXAMPLES

提交前排雷：形式完整仍可能卡在这里



CodeScientist 公开了入选报告和 rejected reports

这些材料最适合用来练习：
怎样区分“产出一份报告”与“研究定义成立”

github.com/allenai/codescientist

常见症状	评委会追问	提交前修正
宏大标题，没有可运行切片	Agent 下一轮究竟能改变什么？	缩小到一个周期内可行动的局部
workflow很完整，研究命题含糊	什么结果会改变你的判断？	写出可证伪主张和失败条件
只报告最终分数	分数变化来自哪里？	记录过程信号、异常与决策轨迹
没有最低参照或强 baseline	Agent 是否只撞中了运气？	加入随机/无干预及最强可行方法
小样本结果被讲成普遍规律	结论适用范围有多大？	预先限定范围并报告不确定性
看到结果后才定义成功	换一个指标会不会结论相反？	预先声明发现信号与停止规则

Q&A

把时间留给现场

欢迎直接描述你的问题：
它为什么重要、你手上有什么数据或模拟器、你准备让
Agent 做什么。

开放探索赛题



BACKUP 01

高频 Q&A (备用)

必须自己构造数据吗？

不必须。可以使用现有数据或模拟器，但要重新定义探索目标与反馈逻辑。

必须有 GPU 吗？

不必须。初赛主要是问题定义，不少最小环境可在 CPU 上运行。

没有正结果可以吗？

可以。需要解释失败或异常改变了我们对问题的什么认识。

社会科学和金融可以吗？

可以。请给出可审计的研究问题；业务收益可以作为背景，不能成为唯一目标。

必须做通用 Agent 吗？

不必须。窄而可信的专用环境往往更适合比赛周期。

BACKUP 02

初赛四页建议结构

PAGE 1

问题与证据

- 01 真实现象或需求
- 02 为什么尚未被结构化
- 03 研究价值与合适切片

PAGE 2

环境接口

- 01 固定规则
- 02 观察 / 行动 / 反馈
- 03 记录与预算

PAGE 3

发现信号与参照

- 01 什么算发现
- 02 平凡解 / 随机 / 无干预
- 03 最低成功与失败标准

PAGE 4

最小验证计划

- 01 一次试跑怎么做
- 02 主要风险与失败路径
- 03 复现与开源计划

这份结构只提供一种组织顺序；评委最终要能准确复述你的问题、环境与最小闭环。

BACKUP 03

主要参考与公开项目

01	Goodhart / Strathern
	European Review 5(3), 305–321 (1997)
02	Benchmark saturation
	Nature Communications 13, 6793 · arXiv:2203.04592
03	AI for Science review
	Nature 620, 47–60 (2023) · DOI:10.1038/s41586-023-06221-2
04	AlphaFold
	Nature 596, 583–589 (2021) · DOI:10.1038/s41586-021-03819-2
05	MatterGen
	arXiv:2312.03687
06	The AI Scientist
	arXiv:2408.06292

07	Autoresearch
	github.com/karpathy/autoresearch
08	Battery-Sim-Agent
	KDD 2026 · DOI:10.1145/3770855.3818856
09	CodeScientist
	Findings of ACL 2025 · arXiv:2503.22708
10	DiscoveryWorld
	NeurIPS 2024 Datasets & Benchmarks
11	S-Researcher
	arXiv:2604.01520
12	TwinMarket
	NeurIPS 2025

案例用于解释方法与边界，不代表照搬其任务即可满足开放赛题要求。